

Taller tres de series de tiempo multivariadas aplicadas

Grupo 2:

- Juan Pablo Rodriguez
- Yosef Guevara Salamanca

1. Encuentre un vector de series de tiempo multivariado con $m \geq 10$. • Construya el modelo de componentes principales con covarianza muestral y correlación muestral. • Haga un reporte de análisis, incluyendo el código.

Cargue de base de datos

La base a continuación muestra los datos de contagios de varicela en 10 condados de Hungría. 522 semanas. Arrancando la medición el 3 de enero de 2005 y termina el 29 de diciembre de 2014

```
varic <- read.csv("VIRUOK.csv", header = TRUE, sep=";")
varic<-as.data.frame(varic)

mvaric<-ts(varic,freq=365.25/7,start=decimal_date(ymd("2005-01-03")))
head(mvaric)

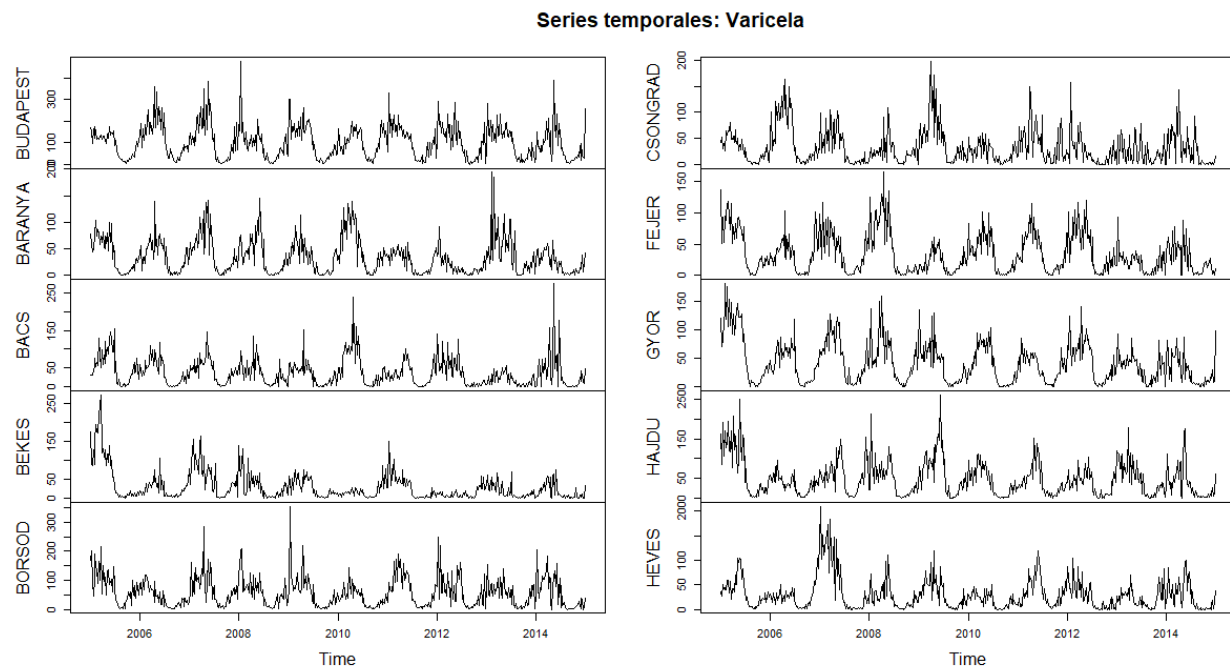
## Time Series:
## Start = 2005.00547945205
## End = 2005.1013042296
## Frequency = 52.1785714285714
##          BUDAPEST BARANYA BACS BEKES BORSOD CSONGRAD FEJER GYOR HAJDU HEVE
S
## 2005.005      168      79   30   173   169        42   136   120   162    3
6
## 2005.025      157      60   30   92   200        53   51    70    84    2
8
## 2005.044       96      44   31   86   93         30   93    84   191    5
1
## 2005.063      163      49   43  126   46         39   52   114   107    4
2
## 2005.082      122      78   53   87  103         34   95   131   172    4
0
## 2005.101      174      76   77  152  189         26   74   181   157    4
4

tail(mvaric)

## Time Series:
## Start = 2014.89459649518
## End = 2014.99042127273
## Frequency = 52.1785714285714
##          BUDAPEST BARANYA BACS BEKES BORSOD CSONGRAD FEJER GYOR HAJDU HEVE
```

```
S
## 2014.895      16      15      14      2      3      0      9      23      6
0
## 2014.914      95      12      41      6      39      0      16      15      14      1
0
## 2014.933      43      39      31      10      34      3      2      30      25      1
9
## 2014.952      35       7      15      0      0      0      7      7      4
2
## 2014.971      30      23      8      0      11      4      1      9      10      1
7
## 2014.990     259      42      49      32      38      15      11      98      61      3
8

#str(mvaric)
#summary(mvaric)
plot(mvaric, main = "Series temporales: Varicela ")
```



Matriz de covarianzas actual : Esta es la matriz que se debe minimizar.

```
cov(mvaric)

##          BUDAPEST   BARANYA      BACS      BEKES      BORSOD   CSONGRAD   FE
JER
## BUDAPEST 5830.066 1473.5389 1661.4216 1348.6685 2508.3848 1523.7130 1250.7
470
## BARANYA  1473.539 1060.6239  658.7662  565.6131  830.0215  512.9745  548.8
904
## BACS     1661.422  658.7662 1357.4136  522.2892  929.6158  510.7380  659.2
003
```

| | | | | | | | |
|--------------------|-----------|-----------|-----------|-----------|-----------|-----------|-------|
| ## BEKES 804 | 1348.668 | 565.6131 | 522.2892 | 1415.1208 | 993.6599 | 456.0988 | 612.6 |
| ## BORSOD 825 | 2508.385 | 830.0215 | 929.6158 | 993.6599 | 2573.0700 | 771.3973 | 917.3 |
| ## CSONGRAD 713 | 1523.713 | 512.9745 | 510.7380 | 456.0988 | 771.3973 | 1141.7782 | 446.5 |
| ## FEJER 337 | 1250.747 | 548.8904 | 659.2003 | 612.6804 | 917.3825 | 446.5713 | 985.8 |
| ## GYOR 063 | 1766.950 | 737.9832 | 835.2418 | 843.7622 | 1109.5743 | 583.2123 | 809.7 |
| ## HAJDU 839 | 1986.644 | 811.7074 | 875.7764 | 939.7649 | 1372.1244 | 621.2190 | 817.4 |
| ## HEVES 050 | 1267.851 | 479.3608 | 576.6580 | 567.9478 | 812.9314 | 473.5118 | 560.2 |
| ## | GYOR | HAJDU | HEVES | | | | |
| ## BUDAPEST | 1766.9503 | 1986.6439 | 1267.8512 | | | | |
| ## BARANYA | 737.9832 | 811.7074 | 479.3608 | | | | |
| ## BACS | 835.2418 | 875.7764 | 576.6580 | | | | |
| ## BEKES | 843.7622 | 939.7649 | 567.9478 | | | | |
| ## BORSOD | 1109.5743 | 1372.1244 | 812.9314 | | | | |
| ## CSONGRAD | 583.2123 | 621.2190 | 473.5118 | | | | |
| ## FEJER | 809.7063 | 817.4839 | 560.2050 | | | | |
| ## GYOR | 1297.0296 | 1079.5523 | 627.7050 | | | | |
| ## HAJDU | 1079.5523 | 1990.1267 | 710.2797 | | | | |
| ## HEVES | 627.7050 | 710.2797 | 1014.9162 | | | | |

Matriz de correlaciones

```
chin<-cor(mvaric)
```

```
chin
```

| | | | | | | | |
|---------------------|-----------|-----------|-----------|-----------|-----------|-----------|-------|
| ## EJER | BUDAPEST | BARANYA | BACS | BEKES | BORSOD | CSONGRAD | F |
| ## BUDAPEST 7121 | 1.0000000 | 0.5925761 | 0.5905912 | 0.4695390 | 0.6476369 | 0.5905757 | 0.521 |
| ## BARANYA 7883 | 0.5925761 | 1.0000000 | 0.5490280 | 0.4616810 | 0.5024384 | 0.4661484 | 0.536 |
| ## BACS 8485 | 0.5905912 | 0.5490280 | 1.0000000 | 0.3768410 | 0.4974181 | 0.4102525 | 0.569 |
| ## BEKES 7229 | 0.4695390 | 0.4616810 | 0.3768410 | 1.0000000 | 0.5207331 | 0.3588156 | 0.518 |
| ## BORSOD 0005 | 0.6476369 | 0.5024384 | 0.4974181 | 0.5207331 | 1.0000000 | 0.4500507 | 0.576 |
| ## CSONGRAD 9186 | 0.5905757 | 0.4661484 | 0.4102525 | 0.3588156 | 0.4500507 | 1.0000000 | 0.420 |
| ## FEJER 0000 | 0.5217121 | 0.5367883 | 0.5698485 | 0.5187229 | 0.5760005 | 0.4209186 | 1.000 |
| ## GYOR 0622 | 0.6425584 | 0.6292031 | 0.6294789 | 0.6227996 | 0.6073732 | 0.4792486 | 0.716 |
| ## HAJDU | 0.5832341 | 0.5586997 | 0.5328399 | 0.5599923 | 0.6063555 | 0.4121103 | 0.583 |

6292

HEVES 0.5212144 0.4620264 0.4913004 0.4739108 0.5030522 0.4398705 0.5600542

GYOR HAJDU HEVES

BUDAPEST 0.6425584 0.5832341 0.5212144

BARANYA 0.6292031 0.5586997 0.4620264

BACS 0.6294789 0.5328399 0.4913004

BEKES 0.6227996 0.5599923 0.4739108

BORSOD 0.6073732 0.6063555 0.5030522

CSONGRAD 0.4792486 0.4121103 0.4398705

FEJER 0.7160622 0.5836292 0.5600542

GYOR 1.0000000 0.6719367 0.5470986

HAJDU 0.6719367 1.0000000 0.4997743

HEVES 0.5470986 0.4997743 1.0000000

xtable(chin)

% latex table generated in R 4.1.0 by xtable 1.8-4 package

% Mon Jun 28 17:47:52 2021

\begin{table}[ht]

\centering

\begin{tabular}{rrrrrrrrrr}

\hline

& BUDAPEST & BARANYA & BACS & BEKES & BORSOD & CSONGRAD & FEJER & GYOR & HAJDU & HEVES \\\

\hline

BUDAPEST & 1.00 & 0.59 & 0.59 & 0.47 & 0.65 & 0.59 & 0.52 & 0.64 & 0.58 & 0.52 \\\

BARANYA & 0.59 & 1.00 & 0.55 & 0.46 & 0.50 & 0.47 & 0.54 & 0.63 & 0.56 & 0.46 \\\

BACS & 0.59 & 0.55 & 1.00 & 0.38 & 0.50 & 0.41 & 0.57 & 0.63 & 0.53 & 0.49 \\\

BEKES & 0.47 & 0.46 & 0.38 & 1.00 & 0.52 & 0.36 & 0.52 & 0.62 & 0.56 & 0.47 \\\

BORSOD & 0.65 & 0.50 & 0.50 & 0.52 & 1.00 & 0.45 & 0.58 & 0.61 & 0.61 & 0.50 \\\

CSONGRAD & 0.59 & 0.47 & 0.41 & 0.36 & 0.45 & 1.00 & 0.42 & 0.48 & 0.41 & 0.44 \\\

FEJER & 0.52 & 0.54 & 0.57 & 0.52 & 0.58 & 0.42 & 1.00 & 0.72 & 0.58 & 0.56 \\\

GYOR & 0.64 & 0.63 & 0.63 & 0.62 & 0.61 & 0.48 & 0.72 & 1.00 & 0.67 & 0.55 \\\

HAJDU & 0.58 & 0.56 & 0.53 & 0.56 & 0.61 & 0.41 & 0.58 & 0.67 & 1.00 & 0.50 \\\

HEVES & 0.52 & 0.46 & 0.49 & 0.47 & 0.50 & 0.44 & 0.56 & 0.55 & 0.50 & 1.00 \\\

\hline

\end{tabular}

\end{table}

Observamos que todas las correlaciones son superiores a 0.4 , esto nos da indicios de correlaciones de fuerza media entre las series de casos de varicela por condado.

Ejecución de PCA

Sin correlación:

```
pca <- princomp(mvaric,cor=F)
pca

## Call:
## princomp(x = mvaric, cor = F)
##
## Standard deviations:
##   Comp.1   Comp.2   Comp.3   Comp.4   Comp.5   Comp.6   Comp.7   C
omp.8
## 108.72068  41.89031  32.47392  28.71967  27.74088  25.73724  23.48420  21.
74903
##   Comp.9   Comp.10
##  20.93456  16.76646
##
## 10 variables and 522 observations.

lds <- pca$loadings
lds


##
## Loadings:
##           Comp.1 Comp.2 Comp.3 Comp.4 Comp.5 Comp.6 Comp.7 Comp.8 Comp.9 Co
mp.10
## BUDAPEST  0.643  0.700           0.181  0.148  0.161
## BARANYA   0.214           -0.249           -0.518  0.704 -0.314
## BACS       0.241           -0.372 -0.599           0.263           -0.467 -0.374
## BEKES      0.224 -0.368           0.668 -0.261  0.359 -0.120 -0.241 -0.270 0
.159
## BORSOD    0.374 -0.233  0.832 -0.296           -0.104
## CSONGRAD  0.200  0.118 -0.114           -0.541 -0.719 -0.158 -0.312
## FEJER      0.206 -0.258 -0.135 -0.177 -0.163  0.106           0.642 0
.616
## GYOR       0.270 -0.237 -0.220           0.153 -0.187           0.462 -0
.740
## HAJDU      0.315 -0.385 -0.108  0.171  0.671 -0.467  0.184
## HEVES      0.193 -0.146 -0.124           -0.357           0.775  0.340 -0.224 -0
.163
##
##           Comp.1 Comp.2 Comp.3 Comp.4 Comp.5 Comp.6 Comp.7 Comp.8 Com
p.9
## SS loadings      1.0    1.0    1.0    1.0    1.0    1.0    1.0    1.0
1.0
## Proportion Var    0.1    0.1    0.1    0.1    0.1    0.1    0.1    0.1
0.1
```

```
## Cumulative Var    0.1    0.2    0.3    0.4    0.5    0.6    0.7    0.8
0.9
##                      Comp.10
## SS loadings        1.0
## Proportion Var     0.1
## Cumulative Var     1.0
```

Podemos observar 10 componentes del modelo: Podemos apreciar que en la primera componente todos los alfa son positivos y mayores a 0.19 , y tenemos participación de todas los condados . En la segunda componente desaparece el condado de Baranya y de Bacs , y empezamos a ver algunos componentes con alfas negativos (la gran mayoría) Para el componente 3 , desaparecen los condados de Budapest y Bekes .

Las 3 ecuaciones de componentes son las siguientes:

```
screplot(pca,type="lines",main="Grafico cp")
```



Podemos ver la proporción en que cada componente explica la varianza total :El quiebre de el grafico de componentes principales permite determinar que el quiebre está en el tercer componente. Calculamos para este modelo la varianza y con estas los porcentajes de la varianza total

```
varpca<-(pca$sdev)^2
vtpca<-sum(varpca)
popca<-varpca/vtpca
varpca
```

```
##      Comp.1      Comp.2      Comp.3      Comp.4      Comp.5      Comp.6      Comp
.7
## 11820.1873  1754.7985  1054.5553   824.8195   769.5564   662.4055   551.50
78
##      Comp.8      Comp.9      Comp.10
##   473.0202   438.2560   281.1141
```

```
vtpca
```

```
## [1] 18630.22
```

```
popca
```

```
##      Comp.1      Comp.2      Comp.3      Comp.4      Comp.5      Comp.6      Comp
.7
## 0.63446309 0.09419097 0.05660456 0.04427320 0.04130689 0.03555543 0.029602
86
##      Comp.8      Comp.9      Comp.10
## 0.02538994 0.02352393 0.01508915
```

Usando el principio de Pareto, podemos decidir solamente tomar los componentes del modelo de análisis por componentes principales hasta donde el total de la varianza sea igual al 80 % , en este caso se tomaría hasta la componente numero4 , que suma 82.84% de la varianza (63.44+9.41+5.66+4.44) . Pero, por el principio de parsimonia , y recordando la conclusión del grafico anterior ,tomaremos solamente hasta la componente número 3 , es decir representaríamos el 78.44 % de la varianza total.

con Correlacion:

```
pca2 <- princomp(mvaric,cor=T)
pca2


## Call:
## princomp(x = mvaric, cor = T)
##
## Standard deviations:
##      Comp.1      Comp.2      Comp.3      Comp.4      Comp.5      Comp.6      Comp.7      C
omp.8
## 2.4132962 0.8689343 0.7928900 0.7532979 0.7082114 0.6585880 0.6306460 0.61
30899
##      Comp.9      Comp.10
## 0.5383369 0.4755210
##
## 10 variables and 522 observations.

lds <- pca2$loadings
lds

##
## Loadings:
##      Comp.1 Comp.2 Comp.3 Comp.4 Comp.5 Comp.6 Comp.7 Comp.8 Comp.9 Co
mp.10
```

```
## BUDAPEST 0.336 0.344 0.186 0.268 0.175 0.191 0.175 0.680 0
.314
## BARANYA 0.314 0.131 -0.244 0.326 -0.507 0.471 -0.413 0.200 -0.164
## BACS 0.308 0.132 -0.639 0.570 -0.358
## BEKES 0.291 -0.489 0.497 0.114 -0.310 0.448 0.242 -0.136 0
.207
## BORSOD 0.323 0.203 0.164 0.677 -0.265 0.324 -0.394 -0
.190
## CSONGRAD 0.269 0.682 0.420 -0.239 -0.355 -0.194 -0.245
## FEJER 0.328 -0.236 -0.196 -0.254 -0.569 -0.438 0.108 0
.440
## GYOR 0.359 -0.175 -0.113 -0.156 -0.255 0.366 -0
.772
## HAJDU 0.329 -0.234 0.258 0.155 0.131 -0.844 0
.118
## HEVES 0.297 0.110 -0.820 0.457 -0
.101
##
## Comp.1 Comp.2 Comp.3 Comp.4 Comp.5 Comp.6 Comp.7 Comp.8 Com
p.9
## SS loadings 1.0 1.0 1.0 1.0 1.0 1.0 1.0 1.0
1.0
## Proportion Var 0.1 0.1 0.1 0.1 0.1 0.1 0.1 0.1
0.1
## Cumulative Var 0.1 0.2 0.3 0.4 0.5 0.6 0.7 0.8
0.9
## Comp.10
## SS loadings 1.0
## Proportion Var 0.1
## Cumulative Var 1.0

scs <- pca2$scores
screplot(pca2,type="lines",main="screplot")
```

Podemos ver la proporción en que cada componente explica la varianza total: El quiebre de el grafico de componentes principales permite determinar que el quiebre está en el tercer o cuarto componente.

```
varpca2<-(pca2$sdev)^2
vtpca2<-sum(varpca2)
popca2<-varpca2/vtpca2
varpca2
```

```
##      Comp.1      Comp.2      Comp.3      Comp.4      Comp.5      Comp.6      Comp.7      C
omp.8
## 5.8239987 0.7550469 0.6286746 0.5674577 0.5015634 0.4337382 0.3977144 0.37
58792
##      Comp.9      Comp.10
## 0.2898066 0.2261203
```

```
vtpca2
```

```
## [1] 10
```

```
popca2
```

```
##      Comp.1      Comp.2      Comp.3      Comp.4      Comp.5      Comp.6      Comp
.7
## 0.58239987 0.07550469 0.06286746 0.05674577 0.05015634 0.04337382 0.039771
44
##      Comp.8      Comp.9      Comp.10
## 0.03758792 0.02898066 0.02261203
```


Usando el principio de Pareto, podemos decidir solamente tomar los componentes del modelo de análisis por componentes principales hasta donde el total de la varianza sea

igual al 80 % , en este caso se tomaría hasta la componente número 3 , que suma 72.06% de la varianza (58.23+7.55+6.28) .

Grafico Sectores por los primeros dos loadings Sacar los 3 pares de graficos C1-C2 , C2-C3 , C1-C3

```
C <- as.data.frame(cbind(lds[,1],lds[,2]))
C
##           V1          V2
## BUDAPEST 0.3359339 0.34381675
## BARANYA  0.3136152 0.13073070
## BACS      0.3078807 0.13207901
## BEKES     0.2906153 -0.48876792
## BORSOD    0.3226918 -0.04498673
## CSONGRAD 0.2688433 0.68193882
## FEJER     0.3284033 -0.23574358
## GYOR      0.3589387 -0.17488224
## HAJDU     0.3287373 -0.23365133
## HEVES     0.2972969 -0.02333325

ggplot(C,aes(C[,1],C[,2],label=rownames(C))) +
  geom_point(size=4,col=3) +
  geom_text(vjust=0,hjust=0,angle = 10,size=5) +
  xlab("Loading 1") +
  ylab("Loading 2")
```




Los grupos que logramos identificar son: 1. Bacs , Heaves y Baranya. 2. Jadu ,Fejer y Borsod Budapest ,Gyor y Csongrad son condados que no pertenecen a ningún cluster como tal. Este ultimo condado se puede observar que aporta en gran medida a el loading 2 , mas no al loading 1, mientras que budapest aporte a ambos en alta cantidad , y Gyor aporta mas a el loading 1 que el loading 2.

```
C <- as.data.frame(cbind(lds[,2],lds[,3]))
C

##           V1           V2
## BUDAPEST  0.34381675  0.060005225
## BARANYA   0.13073070 -0.243735566
## BACS      0.13207901 -0.639361949
## BEKES     -0.48876792  0.497256076
## BORSOD    -0.04498673  0.203127447
## CSONGRAD  0.68193882  0.419778393
## FEJER     -0.23574358 -0.196151970
## GYOR      -0.17488224 -0.113435558
## HAJDU     -0.23365133  0.008218108
## HEVES     -0.02333325  0.109816312

ggplot(C,aes(C[,1],C[,2],label=rownames(C))) +
  geom_point(size=4,col=3) +
  geom_text(vjust=0,hjust=0,angle = 10,size=5) +
  xlab("Loading 2") +
  ylab("Loading 3")
```



El clúster más notorio en este plano es Heves , Borsod ,Gyor ,Fejer y Hajdu.

Se puede observar igualmente que Csongrad aporta tanto para el loading 2 como para el loading 3

```
C <- as.data.frame(cbind(lds[,1],lds[,3]))
C
```

```
##           V1           V2
## BUDAPEST 0.3359339 0.060005225
## BARANYA  0.3136152 -0.243735566
## BACS     0.3078807 -0.639361949
## BEKES    0.2906153 0.497256076
## BORSOD   0.3226918 0.203127447
## CSONGRAD 0.2688433 0.419778393
## FEJER    0.3284033 -0.196151970
## GYOR     0.3589387 -0.113435558
## HAJDU    0.3287373 0.008218108
## HEVES    0.2972969 0.109816312
```

```
ggplot(C,aes(C[,1],C[,2],label=rownames(C))) +
  geom_point(size=4,col=3) +
  geom_text(vjust=0,hjust=0,angle = 10,size=5) +
  xlab("Loading 1") +
  ylab("Loading 3")
```





Gráfico Series de tiempo por scores sobre las dos primeras 2 componentes

```
C <- as.data.frame(cbind(scs[,1],scs[,2]))
palette(rainbow(400))
ggplot(C,aes(C[,1],C[,2],label=substring(rownames(C),1,4))) +
  geom_path() +
  geom_point(size=4,col=1:nrow(C)) +
  geom_text(vjust=0,hjust=0,angle = 10,size=5) +
  xlab("Scoring 1") +
  ylab("Scoring 2")           palette("default")
```



Se observan los siguientes grupos: 1. Borsod , Hajdu , Budapest , Baranya y Fejer. 2. Csongrad y Beres El condado de gyor aporta mucho al eje numero 1 pero no al eje numero 3

Gráfico Series de tiempo por scores sobre las componentes 1 y 3

```
C <- as.data.frame(cbind(scs[,1],scs[,2]))
palette(rainbow(400))
ggplot(C,aes(C[,1],C[,2],label=substring(rownames(C),1,4))) +
  geom_path() +
  geom_point(size=4,col=1:nrow(C)) +
  geom_text(vjust=0,hjust=0,angle = 10,size=5) +
  xlab("Scoring 1") +
  ylab("Scoring 2")

palette("default")
```


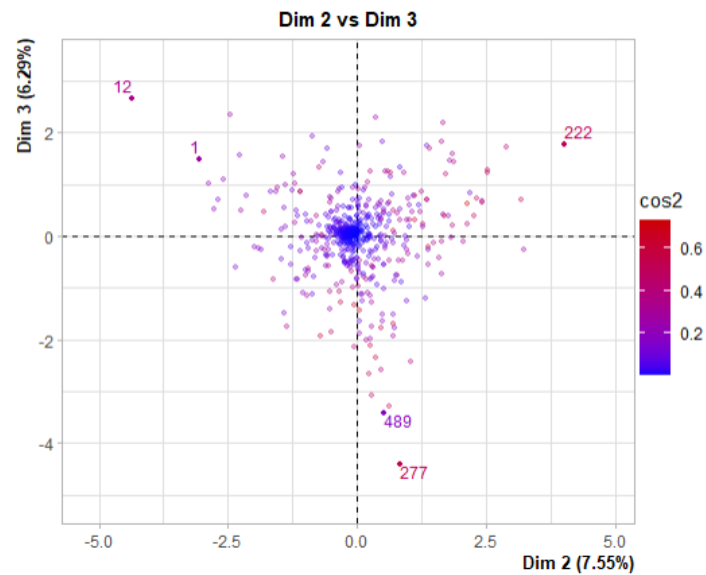


Gráfico Series de tiempo por scores sobre las componentes 2 y 3

```
C <- as.data.frame(cbind(scs[,2],scs[,3]))
palette(rainbow(400))
ggplot(C,aes(C[,1],C[,2],label=substring(rownames(C),1,4))) +
  geom_path() +
  geom_point(size=4,col=1:nrow(C)) +
  geom_text(vjust=0,hjust=0,angle = 10,size=5) +
  xlab("Scoring 1") +
  ylab("Scoring 2")palette("default")
```



2. Considere los retornos mensuales del portafolio 1,2, y 5 de Enero 1961 a Septiembre 2011. (Nombre: m-dec15678-6111.txt)

Se carga la libreria.

```
library(MTS)
```

Se cargan el DataSet

```
da=read.table("m-dec15678-6111.txt",header=T)
head(da)
```

| ## | date | dec1 | dec5 | dec6 | dec7 | dec8 |
|------|----------|-----------|-----------|-----------|-----------|-----------|
| ## 1 | 19610131 | 0.058011 | 0.081767 | 0.084824 | 0.087414 | 0.099884 |
| ## 2 | 19610228 | 0.029241 | 0.055524 | 0.067772 | 0.079544 | 0.079434 |
| ## 3 | 19610330 | 0.025896 | 0.041304 | 0.055696 | 0.065426 | 0.069637 |
| ## 4 | 19610428 | 0.005667 | 0.000780 | 0.005113 | 0.022786 | 0.019822 |
| ## 5 | 19610531 | 0.019208 | 0.049590 | 0.047651 | 0.031453 | 0.047365 |
| ## 6 | 19610630 | -0.024670 | -0.040046 | -0.058176 | -0.056580 | -0.054167 |

Se crea una lista que contiene los deciles 1,5 y 8 de los portafolios que contienen los retornos acciones de las bolsas NYSE, AMEX, y NASDAQ. Cuales valores son transformados mediante logaritmos

```
x=log(da[,2:6]+1)*100
```

Se crea una matriz que contiene los retornos de los deciles 1,5 y 8


```
rtn=cbind(x$dec1,x$dec5,x$dec8)
```

Luego de ello se genera un vector que actuara como indice temporal, que ira desde 1961 a 2012, donde cada año es dividido en 12 meses.

```
tdx=c(1:612)/12+1961
```

Posterior a ello se grafican los logaritmos de los rendimientos mensuales.

```
par(mfrow=c(3,1))
plot(tdx,rtn[,1],type="l",xlab="year",ylab="d1")
plot(tdx,rtn[,2],type="l",xlab="year",ylab="d5")
plot(tdx,rtn[,3],type="l",xlab="year",ylab="d8")
```

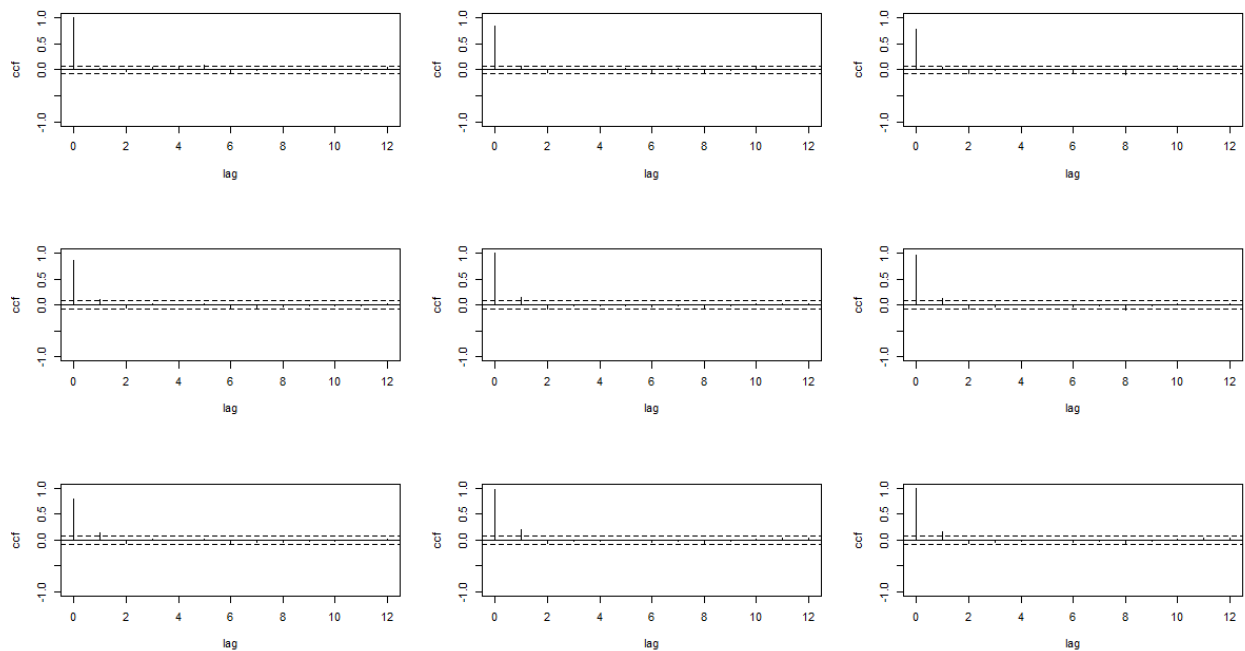



a) Especifique un modelo VMA para el retorno

Para el identificar el orden del modelo primero calcularemos la correlación-cruzada de los retornos


```
ccm(rtn)

## [1] "Covariance matrix:"
##      [,1] [,2] [,3]
## [1,] 18.4 20.2 21.8
## [2,] 20.2 30.7 34.3
## [3,] 21.8 34.3 41.2
## CCM at lag: 0
##      [,1] [,2] [,3]
## [1,] 1.000 0.851 0.791
## [2,] 0.851 1.000 0.964
## [3,] 0.791 0.964 1.000
## Simplified matrix:
## CCM at lag: 1
## . . .
## + + +
## + + +
## CCM at lag: 2
## . . .
## . . .
## . . .
## CCM at lag: 3
```



Hit Enter for p-value plot of individual ccm:

Significance plot of CCM




Gracias al gráfico de correlación cruzada de los retornos se aprecia una dependencia significativa dinámica en el **lag-1**, lo cual es un primer indicativo que un modelo **VMA(1)** sería el apropiado para estas series. No obstante, se resalta que la prueba **Ljung-Box** los **lag-5** y **lag-8** también poseen cierta significancia.

A continuación, se usan los retornos para crear a **zt** y correr el comando **VMAorder**, para especificar el orden del proceso VMA usando la prueba **Ljung-Box**

```
zt <- rtn
VMAorder(zt, lag=20)

## Q(j,m) Statistics:
##      j      Q(j,m)  p-value
## [1,]  1.00    289.86    0.00
## [2,]  2.00    245.19    0.00
## [3,]  3.00    230.80    0.00
## [4,]  4.00    220.44    0.00
## [5,]  5.00    207.33    0.00
## [6,]  6.00    188.41    0.00
## [7,]  7.00    174.40    0.00
## [8,]  8.00    164.90    0.00
## [9,]  9.00    145.01    0.01
## [10,] 10.00    134.08    0.01
## [11,] 11.00    126.17    0.01
## [12,] 12.00    119.47    0.00
## [13,] 13.00     90.13    0.07
## [14,] 14.00     83.01    0.05
## [15,] 15.00     62.89    0.19
## [16,] 16.00     46.80    0.40
## [17,] 17.00     38.47    0.36
## [18,] 18.00     30.68    0.28
## [19,] 19.00     15.79    0.61
## [20,] 20.00      8.76    0.46
```

p-values: Q(j,m) Statistics



Podemos ver que se los $Q_k(1,20), \dots, Q_k(12,20)$, son significativos al 5, por lo cual los resultados no son concluyentes, sin embargo al como parte del principio de parsimonia y apoyados sobre los resultados de la correlación-cruzada, se determina que el orden del modelo es **VMA(1)**.

b) Haga la estimación del modelo con MV.

Para este punto se utiliza el comando VMA para estimar el modelo usando verosimilitud condicional Gaussiana donde $q = 1$, representa el orden de nuestro modelo.

```
VMA1 <- VMA(z1, q = 1)

## Number of parameters: 12
## initial estimates: 0.7025 0.8981 0.9552 0.1131 -0.2658 0.1142 0.1528 -0.5
369 0.242 0.1711 -0.7186 0.3289
## Par. Lower-bounds: 0.495 0.634 0.6518 0.0185 -0.4344 -0.0118 0.0324 -0.75
15 0.0815 0.0327 -0.9651 0.1445
## Par. Upper-bounds: 0.9099 1.1622 1.2586 0.2077 -0.0972 0.2402 0.2733 -0.3
223 0.4025 0.3095 -0.472 0.5132
## Final Estimates: 0.7158762 0.9198663 0.9833664 0.07989616 -0.2626063 0.
1257202 0.1041787 -0.535717 0.26051 0.1213884 -0.7180216 0.3481091
##
## Coefficient(s):
##      Estimate Std. Error t value Pr(>|t|)
## [1,] 0.71588    0.18333   3.905 9.43e-05 ***
## [2,] 0.91987    0.25930   3.548 0.000389 ***
## [3,] 0.98337    0.30212   3.255 0.001134 **
## [4,] 0.07990    0.07552   1.058 0.290087
## [5,] -0.26261   0.13723  -1.914 0.055662 .
## [6,] 0.12572    0.10209   1.232 0.218133
## [7,] 0.10418    0.09690   1.075 0.282321
## [8,] -0.53572   0.17257  -3.104 0.001907 **
## [9,] 0.26051    0.12794   2.036 0.041738 *
## [10,] 0.12139   0.11230   1.081 0.279733
## [11,] -0.71802  0.20017  -3.587 0.000334 ***
## [12,] 0.34811   0.14863   2.342 0.019176 *
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
## ---
## Estimates in matrix form:
## Constant term:
## Estimates: 0.7158762 0.9198663 0.9833664
## MA coefficient matrix
## MA( 1 )-matrix
##      [,1] [,2] [,3]
## [1,] 0.0799 -0.263 0.126
## [2,] 0.1042 -0.536 0.261
## [3,] 0.1214 -0.718 0.348
##
## Residuals cov-matrix:
```

```
##           [,1]      [,2]      [,3]
## [1,] 18.21362 19.76509 21.13788
## [2,] 19.76509 29.54105 32.70033
## [3,] 21.13788 32.70033 39.00978
## ----
## aic= 6.026387
## bic= 6.11299
```

Podemos decir entonces que el modelo estimado por verosimilitud condicional Gaussiana esta dado por:

$$z_t = \begin{bmatrix} 0.72 \\ 0.92 \\ 0.98 \end{bmatrix} + a_t - \begin{bmatrix} 0.080 & -0.263 & 0.126 \\ 0.104 & -0.536 & 0.261 \\ 0.121 & -0.718 & 0.348 \end{bmatrix} a_{t-1}, \hat{\Sigma}_a = \begin{bmatrix} 18.214 & 19.765 & 21.138 \\ 19.765 & 29.541 & 32.700 \\ 21.138 & 32.700 & 39.001 \end{bmatrix}$$

c) Refine el modelo para una t mayor 1.645.

Haciendo uso del comando **refVMA** se refinara el modelo haciendo 0 a todos aquellos parametros no significativos (inferiores) para un umbral de 1.645.

```
r.VMA <- refVMA(VMA1, thres = 1.645)

## Number of parameters: 8
## initial estimates: 0.7159 0.9199 0.9834 0.2626 0.5357 -0.2605 0.718 -0.34
81
## Par. Lower-bounds: 0.3492 0.4013 0.3791 -0.0118 0.1906 -0.5164 0.3177 -0.
6454
## Par. Upper-bounds: 1.0825 1.4385 1.5876 0.5371 0.8809 -0.0046 1.1184 -0.0
508
## Final Estimates: 0.7147405 0.9180014 0.9817448 0.01265214 0.2603929 -0.
2741884 0.3176887 -0.3695367
##
## Coefficient(s):
## Estimate Std. Error t value Pr(>|t|)
## 0.71474 0.17130 4.172 3.01e-05 ***
## 0.91800 0.23515 3.904 9.46e-05 ***
## 0.98174 0.28688 3.422 0.000621 ***
## 0.01265 0.03280 0.386 0.699654
## 0.26039 0.09348 2.786 0.005342 **
## -0.27419 0.07238 -3.788 0.000152 ***
## 0.31769 0.11777 2.697 0.006987 **
## -0.36954 0.09280 -3.982 6.83e-05 ***
## ---
## Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
## ---
## Estimates in matrix form:
## Constant term:
## Estimates: 0.7147405 0.9180014 0.9817448
## MA coefficient matrix
## MA( 1 )-matrix
##           [,1]      [,2]      [,3]
```

```
## [1,]    0 0.0127  0.000
## [2,]    0 0.2604 -0.274
## [3,]    0 0.3177 -0.370
##
## Residuals cov-matrix:
##           [,1]      [,2]      [,3]
## [1,] 18.46597 20.24380 21.73191
## [2,] 20.24380 30.78095 34.31556
## [3,] 21.73191 34.31556 41.12705
## ----
## aic=  6.098651
## bic=  6.156386
```

d) Escriba el modelo ajustado

El modelo refinado esta dado entonces por:

$$z_t = \begin{bmatrix} 0.715 \\ 0.918 \\ 0.982 \end{bmatrix} + a_t - \begin{bmatrix} 0 & 0.0127 & 0.000 \\ 0 & 0.2604 & -0.274 \\ 0 & 0.3177 & -0.370 \end{bmatrix} a_{t-1}, \hat{\Sigma}_a = \begin{bmatrix} 18.467 & 20.245 & 21.732 \\ 20.245 & 30.781 & 34.316 \\ 21.733 & 34.321 & 41.127 \end{bmatrix}$$

e) Use el modelo para pronosticar los retornos

```
prd.VMA <- VMApred(r.VMA)
```

```
## Forecasts at origin: 612
## [1] 0.7165 0.8994 0.9521
## Standard Errors of predictions:
## [1] 4.297 5.548 6.413
```

Tabla comparativa entre el promedio del retorno y su estimado

| Decil | Promedio retorno | Promedio predicción | % de diferencia |
|-------|------------------|---------------------|-----------------|
| dec1 | 0.7143 | 0.7165 | 0.003 |
| dec5 | 0.9171 | 0.8994 | 0.019 |
| dec8 | 0.9805 | 0.9521 | 0.028 |

Tabla comparativa entre la desviación estándar del retorno y su estimado

| Decil | sd retorno | sd predicción | % de diferencia |
|-------|------------|---------------|-----------------|
| dec1 | 4.297 | 4.294 | 0.000 |
| dec5 | 5.548 | 5.536 | 0.002 |
| dec8 | 6.413 | 6.418 | 0.000 |

Se aprecia fatalmente que la diferencia entre los valores estimados para el vector μ , como la desviación estándar σ , no superan el 5 de diferencia, por lo que es posible hablar de nuestro modelo estimado se ajusta correctamente a un proceso *VMA* para los retornos de las acciones de las bolsas NYSE, AMEX, y NASDAQ entre 1961 y 2012.

f) Obtenga los intervalos de confianza del 95%.

Los intervalos de confianza del 95% para nuestro modelo están dados por:

Limite superior.

```
upper<-prd.VMA$pred+1.96*prd.VMA$se  
upper  
##           [,1]      [,2]      [,3]  
## [1,]  9.13902 11.77361 13.52163
```

Limite inferior.

```
lower<-prd.VMA$pred-1.96*prd.VMA$se  
lower  
##           [,1]      [,2]      [,3]  
## [1,] -7.706022 -9.974776 -11.61748
```

Tabla de intervalos de confianza del 95 % para los retornos.

| | Decil | Estimado | Lim. Inferior | Lim. Superior |
|--|-------|----------|---------------|---------------|
| | dec1 | 0.714 | -7.706 | 9.139 |
| | dec5 | 0.917 | -9.975 | 11.774 |
| | dec8 | 0.981 | -11.617 | 13.522 |

En otras palabras:

- El 95% de los retornos estará entre -7.706 y 9.139 para el decil 1.
- El 95% de los retornos estará entre -9.975 y 11.774 para el decil 5.
- El 95% de los retornos estará entre -11.617 y 13.522 para el decil 8.

Estos intervalos de confianza son bastantes amplios debido a que la desviación estándar es grande para cada valor de μ .

3. Haga una simulación de un modelo VARMA(2,1)

Se carga la librería

```
library(MTS)
```

Se establecen los parámetros del modelo VARMA(2,1), que tiene la forma:

$$z_t = \phi_1 z_{t-1} + \phi_2 z_{t-2} + a_t - \theta_1 a_{t-1}$$

```
p1=matrix(c(.816,-1.116,-.623,1.074),2,2)
p2=matrix(c(-.643,.615,.592,-.133),2,2)
phi=cbind(p1,p2)
t1=matrix(c(0,-.801,-1.248,0),2,2)
Sig=matrix(c(4,2,2,5),2,2)
```

Cuyos parámetros son:

$$\phi_1 = \begin{bmatrix} 0.816 & -0.623 \\ -1.116 & 1.074 \end{bmatrix}, \phi_2 = \begin{bmatrix} -0.643 & 0.592 \\ 0.615 & -0.133 \end{bmatrix}, \theta_1 = \begin{bmatrix} 0 & -1.248 \\ -0.801 & 0 \end{bmatrix}, \sum_a = \begin{bmatrix} 4 & 2 \\ 2 & 5 \end{bmatrix}$$

a) Genere 500 muestras del modelo VARMA(2,1).

Se establece una semilla para que sea posible replicar los resultados de la simulación, esta simulación se lleva a cabo con 500 muestras.


```
set.seed(123)
m1=VARMAsim(500,arlags=c(1,2),malags=c(1),phi=phi,
            theta=t1,sigma=Sig)
```

A continuación, se extraen los valores de las series calculadas por la simulación.

```
zt = m1$series
```

Luego de esto se visualizan las series simuladas.

```
par(mfrow=c(2,1))
plot(zt[,1],type="l",xlab="index",ylab="S1")
plot(zt[,2],type="l",xlab="index",ylab="S2")
```

b) Ajuste el modelo VARMA(2,1))

Para ajustar el modelo VARMA utilizamos el siguiente comando. Donde p es el orden del modelo autoregresivo y q es el orden del modelo de promedio móvil.

```
m2 = VARMA(z1,p=2,q=1)

## Number of parameters: 14
## initial estimates: 0.044 0.047 0.8812 -0.4603 -0.6048 0.4338 -1.1538 1.10
59 0.6403 -0.175 -0.1188 1.0655 0.7111 0.0039
## Par. lower-bounds: -0.1469 -0.1637 0.7628 -0.5948 -0.731 0.3179 -1.2845 0
.9573 0.5009 -0.3029 -0.2772 0.9018 0.5362 -0.1769
## Par. upper-bounds: 0.2348 0.2577 0.9996 -0.3257 -0.4785 0.5497 -1.0231 1.
2545 0.7797 -0.047 0.0396 1.2292 0.886 0.1847
## Final Estimates: -0.02464951 -0.02234764 0.7976173 -0.5816991 -0.622185
6 0.5497242 -1.222008 1.098673 0.6872336 -0.1584941 0.03963374 1.150714 0.825
841 -0.008606726
##
## Coefficient(s):
##      Estimate Std. Error t value Pr(>|t|)
## [1,] -0.024650 0.179965 -0.137 0.8911
## [2,] -0.022348 0.150164 -0.149 0.8817
## [3,] 0.797617 0.095762 8.329 < 2e-16 ***
## [4,] -0.581699 0.104687 -5.557 2.75e-08 ***
## [5,] -0.622186 0.117103 -5.313 1.08e-07 ***
## [6,] 0.549724 0.080537 6.826 8.75e-12 ***
## [7,] -1.222008 0.075164 -16.258 < 2e-16 ***
## [8,] 1.098673 0.087665 12.533 < 2e-16 ***
```

```

## [9,] 0.687234 0.097231 7.068 1.57e-12 ***
## [10,] -0.158494 0.063948 -2.478 0.0132 *
## [11,] 0.039634 0.095627 0.414 0.6785
## [12,] 1.150714 0.106489 10.806 < 2e-16 ***
## [13,] 0.825841 0.074845 11.034 < 2e-16 ***
## [14,] -0.008607 0.095364 -0.090 0.9281
## ---
## Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
## ---
## Estimates in matrix form:
## Constant term:
## Estimates: -0.02464951 -0.02234764
## AR coefficient matrix
## AR( 1 )-matrix
##      [,1] [,2]
## [1,] 0.798 -0.582
## [2,] -1.222 1.099
## AR( 2 )-matrix
##      [,1] [,2]
## [1,] -0.622 0.550
## [2,] 0.687 -0.158
## MA coefficient matrix
## MA( 1 )-matrix
##      [,1] [,2]
## [1,] -0.0396 -1.15071
## [2,] -0.8258 0.00861
##
## Residuals cov-matrix:
##      [,1] [,2]
## [1,] 3.915255 1.952316
## [2,] 1.952316 5.268900
## ----
## aic= 2.878423
## bic= 2.996432

```

Al ajustar nuestro modelo tenemos que este dado por:

$$z_t = \begin{bmatrix} -0.025 \\ -0.022 \end{bmatrix} + \begin{bmatrix} 0.798 & -0.582 \\ -1.222 & 1.099 \end{bmatrix} z_{t-1} + \begin{bmatrix} -0.622 & 0.550 \\ 0.687 & -0.158 \end{bmatrix} z_{t-2} + a_t - \begin{bmatrix} -0.040 & -1.151 \\ -0.826 & 0.009 \end{bmatrix} a_{t-1}, \Sigma_a = \begin{bmatrix} 3.915 & 1.952 \\ 1.952 & 5.269 \end{bmatrix}$$

Podemos ver con claridad que las diferencias entre las matrices ϕ_1 , ϕ_2 , θ_1 y σ son minimas, por lo que se puede hablar que existe un buen ajuste del modelo

c) Escriba los modelos ajustados

Haciendo uso del comando **refVARMA** se refinará el modelo haciendo 0 a todos aquellos parámetros no significativos (inferiores) para un umbral de 0.8. Este modelo se refinará múltiples veces para verificar la calidad del mismo mediante el uso de los criterios de información *AIC* y *BIC*.

```
m2a = refVARMA(m2, thres=0.8)
```

```

## Number of parameters: 10
## initial estimates: 0.7976 -0.5817 -0.6222 0.5497 -1.222 1.0987 0.6872 -0.
1585 1.1507 0.8258
## Par. lower-bounds: 0.6061 -0.7911 -0.8564 0.3887 -1.3723 0.9233 0.4928 -0
.2864 0.9377 0.6762
## Par. upper-bounds: 0.9891 -0.3723 -0.388 0.7108 -1.0717 1.274 0.8817 -0.0
306 1.3637 0.9755
## Final Estimates: 0.8183532 -0.6335804 -0.6677967 0.5923068 -1.183326 1.
084903 0.6466335 -0.1499602 1.212943 0.7742532
##
## Coefficient(s):
## Estimate Std. Error t value Pr(>|t|)
## 0.81835 0.02829 28.924 < 2e-16 ***
## -0.63358 0.09837 -6.441 1.19e-10 ***
## -0.66780 0.06805 -9.813 < 2e-16 ***
## 0.59231 0.08416 7.038 1.95e-12 ***
## -1.18333 0.06239 -18.967 < 2e-16 ***
## 1.08490 0.03267 33.208 < 2e-16 ***
## 0.64663 0.05535 11.683 < 2e-16 ***
## -0.14996 0.02668 -5.620 1.91e-08 ***
## 1.21294 0.10116 11.990 < 2e-16 ***
## 0.77425 0.06497 11.916 < 2e-16 ***
## ---
## Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
## ---
## Estimates in matrix form:
## Constant term:
## Estimates: 0 0
## AR coefficient matrix
## AR( 1 )-matrix
## [,1] [,2]
## [1,] 0.818 -0.634
## [2,] -1.183 1.085
## AR( 2 )-matrix
## [,1] [,2]
## [1,] -0.668 0.592
## [2,] 0.647 -0.150
## MA coefficient matrix
## MA( 1 )-matrix
## [,1] [,2]
## [1,] 0.000 -1.21
## [2,] -0.774 0.00
##
## Residuals cov-matrix:
## [,1] [,2]
## [1,] 3.946365 1.966623
## [2,] 1.966623 5.275611
## ----
## aic= 2.870379
## bic= 2.954671

```

El modelo refinado **m2a** del modelo **m1** con *thres* = 0.8, por lo cual todos los coeficientes que tengan un *tvalue* menor a 0.8 fueron reducidos a 0 este dado por:

$$z_t = \begin{bmatrix} 0.818 & -0.634 \\ -1.183 & 1.085 \end{bmatrix} z_{t-1} + \begin{bmatrix} -0.668 & 0.592 \\ 0.647 & -0.150 \end{bmatrix} z_{t-2} + a_t - \begin{bmatrix} 0.00 & -1.21 \\ -0.774 & 0.00 \end{bmatrix} a_{t-1}, \hat{\Sigma}_a = \begin{bmatrix} 3.946 & 1.967 \\ 1.967 & 5.276 \end{bmatrix}$$

```
m2b = refVARMA(m2a,thres=1)
```

```
## Number of parameters: 10
## initial estimates: 0.8184 -0.6336 -0.6678 0.5923 -1.1833 1.0849 0.6466 -0.
.15 1.2129 0.7743
## Par. lower-bounds: 0.7618 -0.8303 -0.8039 0.424 -1.3081 1.0196 0.5359 -0.
2033 1.0106 0.6443
## Par. upper-bounds: 0.8749 -0.4368 -0.5317 0.7606 -1.0586 1.1502 0.7573 -0.
.0966 1.4153 0.9042
## Final Estimates: 0.8183533 -0.6335805 -0.6677967 0.5923064 -1.183326 1.
084903 0.6466338 -0.1499607 1.212943 0.7742531
##
## Coefficient(s):
## Estimate Std. Error t value Pr(>|t|)
## 0.81835 0.02829 28.924 < 2e-16 ***
## -0.63358 0.09838 -6.440 1.19e-10 ***
## -0.66780 0.06805 -9.813 < 2e-16 ***
## 0.59231 0.08416 7.038 1.95e-12 ***
## -1.18333 0.06239 -18.967 < 2e-16 ***
## 1.08490 0.03267 33.208 < 2e-16 ***
## 0.64663 0.05535 11.683 < 2e-16 ***
## -0.14996 0.02668 -5.620 1.91e-08 ***
## 1.21294 0.10116 11.990 < 2e-16 ***
## 0.77425 0.06497 11.916 < 2e-16 ***
## ---
## Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
## ---
## Estimates in matrix form:
## Constant term:
## Estimates: 0 0
## AR coefficient matrix
## AR( 1 )-matrix
## [,1] [,2]
## [1,] 0.818 -0.634
## [2,] -1.183 1.085
## AR( 2 )-matrix
## [,1] [,2]
## [1,] -0.668 0.592
## [2,] 0.647 -0.150
## MA coefficient matrix
## MA( 1 )-matrix
## [,1] [,2]
## [1,] 0.000 -1.21
## [2,] -0.774 0.00
##
```

```
## Residuals cov-matrix:
##      [,1] [,2]
## [1,] 3.946365 1.966622
## [2,] 1.966622 5.275611
## ----
## aic= 2.870379
## bic= 2.954671
```

El modelo refinado **m2b** del modelo **m2a** con *thres* = 1 este dado por:

$$z_t = \begin{bmatrix} 0.818 & -0.634 \\ -1.183 & 1.085 \end{bmatrix} z_{t-1} + \begin{bmatrix} -0.668 & 0.592 \\ 0.647 & -0.150 \end{bmatrix} z_{t-2} + a_t - \begin{bmatrix} 0.00 & -1.21 \\ -0.774 & 0.00 \end{bmatrix} a_{t-1}, \Sigma_a = \begin{bmatrix} 3.946 & 1.967 \\ 1.967 & 5.276 \end{bmatrix}$$

```
m2c = refVARMA(m2b,thres=1)
```

```
## Number of parameters: 10
## initial estimates: 0.8184 -0.6336 -0.6678 0.5923 -1.1833 1.0849 0.6466 -0.15 1.2129 0.7743
## Par. lower-bounds: 0.7618 -0.8303 -0.8039 0.424 -1.3081 1.0196 0.5359 -0.2033 1.0106 0.6443
## Par. upper-bounds: 0.8749 -0.4368 -0.5317 0.7606 -1.0586 1.1502 0.7573 -0.0966 1.4153 0.9042
## Final Estimates: 0.8183533 -0.6335805 -0.6677967 0.5923064 -1.183326 1.084903 0.6466338 -0.1499607 1.212943 0.7742531
##
## Coefficient(s):
## Estimate Std. Error t value Pr(>|t|)
## 0.81835 0.02829 28.924 < 2e-16 ***
## -0.63358 0.09837 -6.440 1.19e-10 ***
## -0.66780 0.06805 -9.813 < 2e-16 ***
## 0.59231 0.08416 7.038 1.95e-12 ***
## -1.18333 0.06239 -18.967 < 2e-16 ***
## 1.08490 0.03267 33.208 < 2e-16 ***
## 0.64663 0.05535 11.683 < 2e-16 ***
## -0.14996 0.02668 -5.620 1.91e-08 ***
## 1.21294 0.10116 11.990 < 2e-16 ***
## 0.77425 0.06497 11.916 < 2e-16 ***
## ---
## Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
## ---
## Estimates in matrix form:
## Constant term:
## Estimates: 0 0
## AR coefficient matrix
## AR( 1 )-matrix
##      [,1] [,2]
## [1,] 0.818 -0.634
## [2,] -1.183 1.085
## AR( 2 )-matrix
##      [,1] [,2]
## [1,] -0.668 0.592
```

```
## [2,] 0.647 -0.150
## MA coefficient matrix
## MA( 1 )-matrix
##      [,1] [,2]
## [1,] 0.000 -1.21
## [2,] -0.774 0.00
##
## Residuals cov-matrix:
##      [,1] [,2]
## [1,] 3.946365 1.966622
## [2,] 1.966622 5.275611
## ----
## aic= 2.870379
## bic= 2.954671
```

El modelo refinado **m2c** del modelo **m2b** con *thres* = 1 este dado por:

$$z_t = \begin{bmatrix} 0.818 & -0.634 \\ -1.183 & 1.085 \end{bmatrix} z_{t-1} + \begin{bmatrix} -0.668 & 0.592 \\ 0.647 & -0.150 \end{bmatrix} z_{t-2} + a_t - \begin{bmatrix} 0.00 & -1.21 \\ -0.774 & 0.00 \end{bmatrix} a_{t-1}, \hat{\Sigma}_a = \begin{bmatrix} 3.946 & 1.967 \\ 1.967 & 5.276 \end{bmatrix}$$

Tabla comparativa de los criterios de información de los modelos VARMA(2,1)

| Modelo | AIC | BIC | Umbral |
|--------|------|------|-------------|
| m1 | 2.87 | 2.99 | Sin refinar |
| m2a | 2.87 | 2.95 | 0.8 |
| m2b | 2.87 | 2.95 | 1 |
| m2c | 2.87 | 2.95 | 1 |

Esta tabla nos permite apreciar que no existe ningún cambio en los valores de las matrices ϕ_1 , ϕ_2 , θ_1 y σ^2 , pues el **thres=1** establecido es muy bajo y todos los valores para el modelo refinado son significativos, por lo que no tiene sentido incrementarlo. No obstante, los criterios de información muestran que existe una pequeña diferencia entre el modelo **refinado** y el **no refinado** como lo muestra la ecuación estimada del modelo **VARMA** y el criterio *BIC*

d) Interprete la FACE de los residuos.

Para calcular el FACE se calcula las matrices de correlación cruzada extendidas y la tabla asociada de dos vías de valores p de las estadísticas Ljung-Box de nuestra serie simulada. Donde **maxp** es el orden máximo del orden **AR** y **maxq** es el orden máximo del orden **MA**.

```
zt=m1$series
m2=Eccm(zt,maxp=5,maxq=6)

## p-values table of Extended Cross-correlation Matrices:
## Column: MA order
## Row : AR order
##      0      1      2      3      4      5      6
## 0 0.0000 0.0000 0.0000 0.0000 0.0000 0.0000 0.0000
## 1 0.0000 0.0000 0.0000 0.0000 0.0000 0.0002 0.0044
```

```
## 2 0.0000 0.9478 0.8493 0.3954 0.9369 0.4122 0.9717
## 3 0.0000 0.9187 0.6528 0.8545 0.0947 0.9520 0.9931
## 4 0.0002 0.9283 0.9815 0.9081 1.0000 0.8287 0.8726
## 5 0.0009 0.1516 0.9998 1.0000 0.9835 0.9983 0.9964
```

Tabla de comportamiento asintótico de valores p de dos vías para una serie temporal VARMA(2,1) de dos dimensiones del modelo

| | Orden AR | Orden MA | | | | | |
|---|----------|----------|---|---|---|---|---|
| p | 0 | 1 | 2 | 3 | 4 | 5 | 6 |
| 0 | X | X | X | X | X | X | X |
| 1 | X | X | X | X | X | X | X |
| 2 | X | 0 | 0 | 0 | 0 | 0 | 0 |
| 3 | X | 0 | 0 | 0 | 0 | 0 | 0 |
| 4 | X | 0 | 0 | 0 | 0 | 0 | 0 |
| 5 | X | 0 | 0 | 0 | 0 | 0 | 0 |

Esta tabla muestra el patrón asintótico del modelo **VARMA(2,1)**, donde *X* de nota un valor significativo y *0* un valor no significativo. Se aprecia con claridad que el modelo es un **VARMA(2,1)**, pues los valores significativos de para los procesos **AR** ocupan las primeras 2 filas y los valores significativos del proceso **MA** ocupan la primera columna, es decir que el primer 0 o valor no significativo se encuentra en la fila 2 columna 1.

Si este proceso se repite sobre los residuales de uno del modelo refinados.

```
rsd <- m2a$residuals
Eccm(rsd, maxp = 5, maxq = 6)

## p-values table of Extended Cross-correlation Matrices:
## Column: MA order
## Row : AR order
##      0      1      2      3      4      5      6
## 0 0.8861 0.7994 0.6640 0.6613 0.5807 0.5252 0.5194
## 1 0.9251 0.8114 0.4400 0.4058 0.4845 0.1684 0.7946
## 2 0.9568 0.6952 0.6685 0.6592 0.9291 0.8471 0.7917
## 3 0.9922 0.8429 0.8698 0.6703 0.9294 0.8077 0.8480
## 4 0.9989 0.9858 0.9991 0.9812 0.4109 0.3910 0.7628
## 5 0.9999 0.9679 0.9999 0.9936 0.6510 0.4906 0.6510
```

Donde se ve evidencia no existe una correlación entre los residuales, pues todos los valores no son significativos al ser ellos mayores que 0.05, es decir los residuales son independientes entre sí.

Tabla de comportamiento asintótico de valores p de dos vías para una serie temporal VARMA(2,1) de dos dimensiones de los residuales

| Orden AR | Orden MA | | | | | | | |
|----------|----------|---|---|---|---|---|---|--|
| p | 0 | 1 | 2 | 3 | 4 | 5 | 6 | |
| 0 | 0 | 0 | 0 | 0 | 0 | 0 | 0 | |
| 1 | 0 | 0 | 0 | 0 | 0 | 0 | 0 | |
| 2 | 0 | 0 | 0 | 0 | 0 | 0 | 0 | |
| 3 | 0 | 0 | 0 | 0 | 0 | 0 | 0 | |
| 4 | 0 | 0 | 0 | 0 | 0 | 0 | 0 | |
| 5 | 0 | 0 | 0 | 0 | 0 | 0 | 0 | |